电子商务系统结构实验三选做题

实验要求

阅读论文全文，使用真实数据集按论文的步骤重复论文实验，实验结果与论文结果对比，在实验报告中给出截图并分析。

数据集

使用http://grouplens.org/datasets/movielens/中的 `ml-latest-small` 数据集。总共有600多个用户和。用户评分在1-5之间，可有小数点。0代表没有评分。
选择这个数据集是因为这个数据集的大小较小，方便测试，并且数据比较新。

算法细节

本次选做题要求对比三种不同算法的准确度。

- Cosine算法
  这个算法是最简单的算法，物品的相似度使用两个物品的用户评分向量夹角余弦值。公式如下：

$$sim(i,j) = cos(\vec{i},\vec{j}) = \frac{\vec{i}\cdot\vec{j}}{\left\|\vec{i}\right\|_2 \times \left\|\vec{j}\right\|_2}$$

  其中，$\vec{i}$和$\vec{j}$分别为第i个物品和第j个物品的用户评分向量。
- Correlation-based
  这个算法使用Pearson相关系数作为两个物品的相似度。Pearson相关系数是余弦相似度的一种改进，对向量进行去中心化，使得结果更加准确。其公式为：

$$sim(i,j) = \frac{\sum_{u\in U}(R_{u,i}-\bar{R}_i)(R_{u,j}-\bar{R}_j)}{\sqrt{\sum_{u\in U}(R_{u,i}-\bar{R}_i)^2}\sqrt{\sum_{u\in U}(R_{u,j}-\bar{R}_j)^2}}$$

  其中集合U为经过过滤筛选的用户，一般为同时对这两个物品进行评分的用户集合。$R_{u,i}$为用户u对物品i的评分，$\bar{R}_i$为物品i的平均得分。
- Adjusted Cosine
  这个算法是对以上两个算法的改进。因为上面两个算法都只针对了物品，但是我们同时也应该考

虑到每个用户的评分标准不一样，所以我们去中心化的时候，不采用物品的平均得分，而采用用户的平均给分，可以对算法进行改进。

$$sim(i,j)=\frac{\sum_{u\in U}(R_{u,i}-\bar{R_u})(R_{u,j}-\bar{R_u})}{\sqrt{\sum_{u\in U}(R_{u,i}-\bar{R_u})^2}\sqrt{\sum_{u\in U}(R_{u,j}-\bar{R_u})^2}}$$

这里集合U和$R_{u,i}$定义跟上一个算法一样，而$\bar{R_u}$则为用户u的平均打分。

- Predict
  有了物品之间的相似度，我们还要根据这个相似度针对某个用户对某个物品的评分进行预测。这里采用最简单的加权平均，即其他物品与该物品的相似度作为权，用户对其他物品的评分作为值进行加权平均：

$$P_{u,i}=\frac{\sum_{\text{all similar items, N}}(s_{i,N}\times R_{u,N})}{\sum_{\text{all similar items, N}}(|s_{i,N}|)}$$

这里N表示与改物体相似的其他物体集的一个元素，$s_{i,N}$为物体i与物体N的相似度，$R_{u,N}$为用户u对物体i的评分。

- MAE
  对于算法准确度评估，我们使用MAE进行衡量。
  根据论文中的定义，MAE的定义如下：

$$MAE=\frac{\sum_{i=1}^{N}|p_i-q_i|}{N}$$

其中N为测试数据大小，p_i为预测评分，q_i为实际评分。

代码实现

本次实现为了开发效率，采用了 `python` 进行开发，但是相对地运行效率不是很理想，使用小数据集也能运行一个多小时。

- 读取数据
  数据集为csv文件，可以使用 `python` 原生提供的csv读取库，但后来发现有更好的 `pandas` 库，所以实验中混用两种库。
  1. 统计数据集数据。
     数据集中的用户id是从1开始排序的，但是物品（电影）id并不是从1开始排序的，所以需要对物品id进行一个映射，同时也对用户id进行同样的映射。

```
    @staticmethod
    def __get_id_map(csv_path, row_id):
        id_map = TwoWayDict()
        with open(csv_path, newline='') as csv_file:
            csv_reader = csv.DictReader(csv_file)
            id_set = set()
            for row in csv_reader:
                id_set.add(row[row_id])
            for i in range(id_set.__len__()):
                pop = id_set.pop()
                id_map[i] = pop
    return id_map
```

其中 `TwoWayDict` 为自己实现的字典，可以从键读取到值，也可以从值读取到键。实现比较简单，这里不详细解释这个类。
在进行统计时候，先使用了 `set` 进行id保存，这里出于两个目的：可以筛选重复值，另外 `set` 中的hash比较随机，可以使得后面分离数据集和测试集时候有随机性。

2. 建立用户-物品矩阵
   实验协同过滤算法的首要步骤就是建立一个用户-物品矩阵，然后才能从中获取向量代入算法中的公式计算。

```
    def __build_matrix(self, csv_path, user_id_name, item_id_name, rating_id):
        csv_data = pd.read_csv(csv_path)
        self.__matrix = np.zeros([self.user_size(), self.item_size()])

        def __assign_matrix(row):
            user_id = str(int(row[user_id_name]))
            item_id = str(int(row[item_id_name]))
            user_index = self.__user_id.get_key(user_id)
            item_index = self.__item_id.get_key(item_id)
            self.__matrix[user_index, item_index] = row[rating_id]

        csv_data.apply(__assign_matrix, axis=1)
```

3. 分离训练集和测试集
   这里采用了简单的分离方法，直接分离相应数量的列。因为建立矩阵时候使用了 `set` ，所以分离之后还是有一点随机性的。

```
    self.__train_size = int(self.__matrix.shape[0] * ratio)
    self.__test_size = self.__matrix.shape[0] - self.__train_size
    self.__train_matrix = self.__matrix[:self.__train_size, :]
    self.__test_matrix = self.__matrix[self.__train_size:, :]
```

- 实现Cosine算法
  Cosine算法实现比较简单，直接取出两列然后算夹角余弦就可以了。这里迭代时候保证 `j>i` ，可以减少一半工作量，并且去除自相似的情况（即自己更自己的相似度为1）。

```
def __item_cosine(self, i, j):
    vector_i = self.__train_matrix[:, i]
    vector_j = self.__train_matrix[:, j]
    sq_len = np.sum(np.square(vector_i)) * np.sum(np.square(vector_j))
    if sq_len == 0:
        return 0
    return np.dot(vector_i, vector_j) / np.sqrt(sq_len)

def __train_cosine(self):
    similarity = np.zeros([self.item_size(), self.item_size()])
    for i in range(self.item_size()):
        for j in range(i+1, self.item_size()):
            similarity[i, j] = similarity[j, i] = self.__item_cosine(i, j)
    self.__similarity = similarity
```

- 实现Correlation算法
  实现Correlation算法之前我们应该对用户进行筛选的。但是我们使用的数据集用户较少，而且为了运行时间考虑，这里不对用户进行筛选。
  训练前先算出每个物品的平均评分，然后再取出两个物品代入公式计算。

```
def __item_correlation(self, i, j, mean):
    vector_i = self.__train_matrix[:, i] - mean[i]
    vector_j = self.__train_matrix[:, j] - mean[j]
    sq_len = np.sum(np.square(vector_i)) * np.sum(np.square(vector_j))

    if sq_len == 0:
        return 0
    return np.dot(vector_i, vector_j) / np.sqrt(sq_len)

def __train_correlation(self):
    similarity = np.zeros([self.item_size(), self.item_size()])
    mean = [0] * self.item_size()
    for i in range(self.item_size()):
        item = self.__train_matrix[:, i]
        count = item[item > 0].shape[0]
        if count > 0:
            mean[i] = np.sum(item) / count
        else:
            mean[i] = 0
    for i in range(self.item_size()):
        for j in range(i+1, self.item_size()):
            similarity[i, j] = similarity[j, i] = self.__item_correlation(i, j, mea
    self.__similarity = similarity
```

- 实现Adjust算法
  跟Correlation算法实现相似，略去筛选用户步骤。先对用户平均评分进行计算，然后得出用户平均评分向量，在计算前对物品评分向量减去用户平均评分向量即可。

```
    def __item_adjusted(self, i, j, mean):
        vector_i = self.__train_matrix[:, i] - mean
        vector_j = self.__train_matrix[:, j] - mean
        sq_len = np.sum(np.square(vector_i)) * np.sum(np.square(vector_j))
        if sq_len == 0:
            return 0
        return np.dot(vector_i, vector_j) / np.sqrt(sq_len)

    def __train_adjusted(self):
        similarity = np.zeros([self.item_size(), self.item_size()])
        mean = np.array([0] * self.__train_size, dtype=float)
        for i in range(self.__train_size):
            user = self.__train_matrix[i, :]
            count = user[user > 0].shape[0]
            if count > 0:
                mean[i] = np.sum(user) / count
            else:
                mean[i] = 0
        for i in range(self.item_size()):
            for j in range(i+1, self.item_size()):
                similarity[i, j] = similarity[j, i] = self.__item_adjusted(i, j, mean)
        self.__similarity = similarity
```

以上几个算法都需要考虑零向量的问题。算出零向量的时候，可以断言已知用户集中，这两个物品的评分用户几乎没有交际，所以相似度可视为0。

- 预测与评估
  预测和评估也很简单，对于测试集的每一行（每一个用户），用用户评分向量乘以相似度再求和（点积），即可得到每个用户已经评分的物品的预测值（这里计算时不需要考虑这个物品本身的对自己预测评分的影响，因为自己跟自己的相似度我们设定为0了），然后除以相似度之和即可。

```
    def evaluate(self):
        item_sum = np.sum(self.__similarity, axis=0)
        idx = np.flatnonzero(item_sum)  # indices of non-zero columns
        # remove columns and rows
        similarity = self.__similarity[:, idx][idx, :]
        test = self.__test_matrix[:, idx]
        predict = np.dot(test, similarity) / np.sum(similarity, axis=0)
        return np.mean(np.abs(test - predict))
```

最后用实例向量与测试向量相见、求绝对值平均，就得到MAE了。
更多代码细节可以查看源代码。

测试结果

下图为测试结果的截图。

```
    def evaluate(self):
        item_sum = np.sum(self.__similarity, axis=0)
        idx = np.flatnonzero(item_sum)  # indices of non-zero columns
        # remove columns and rows
        similarity = self.__similarity[:, idx][idx, :]
        test = self.__test_matrix[:, idx]
        predict = np.dot(test, similarity) / np.sum(similarity, axis=0)
        return np.mean(np.abs(test - predict))

    @staticmethod
    def __get_id_map(csv_path, row_id):
        id_map = TwoWayDict()
        with open(csv_path, newline='') as csv_file:
            csv_reader = csv.DictReader(csv_file)
            id_set = set()
            for row in csv_reader:
                id_set.add(row[row_id])
            for i in range(id_set.__len__()):
                pop = id_set.pop()
                id_map[i] = pop
            return id_map


recommend = Recommend("ml-latest-small/ratings.csv", 'movieId', 'userId', 'rating')
recommend.train("cosine")
print(recommend.evaluate())
recommend.train("correlation")
print(recommend.evaluate())
recommend.train("adjusted")
print(recommend.evaluate())
```

```
/usr/bin/python3.5 /home/lovesy/Course/Ecommerce/Main.py
0.151233718473
0.113732082024
0.108639463807

Process finished with exit code 0
```

从上到下分别为Cosine、Correlation和Adjust算法的运行结果（MAE）了。
根据这个结果我们可以画出柱状图：

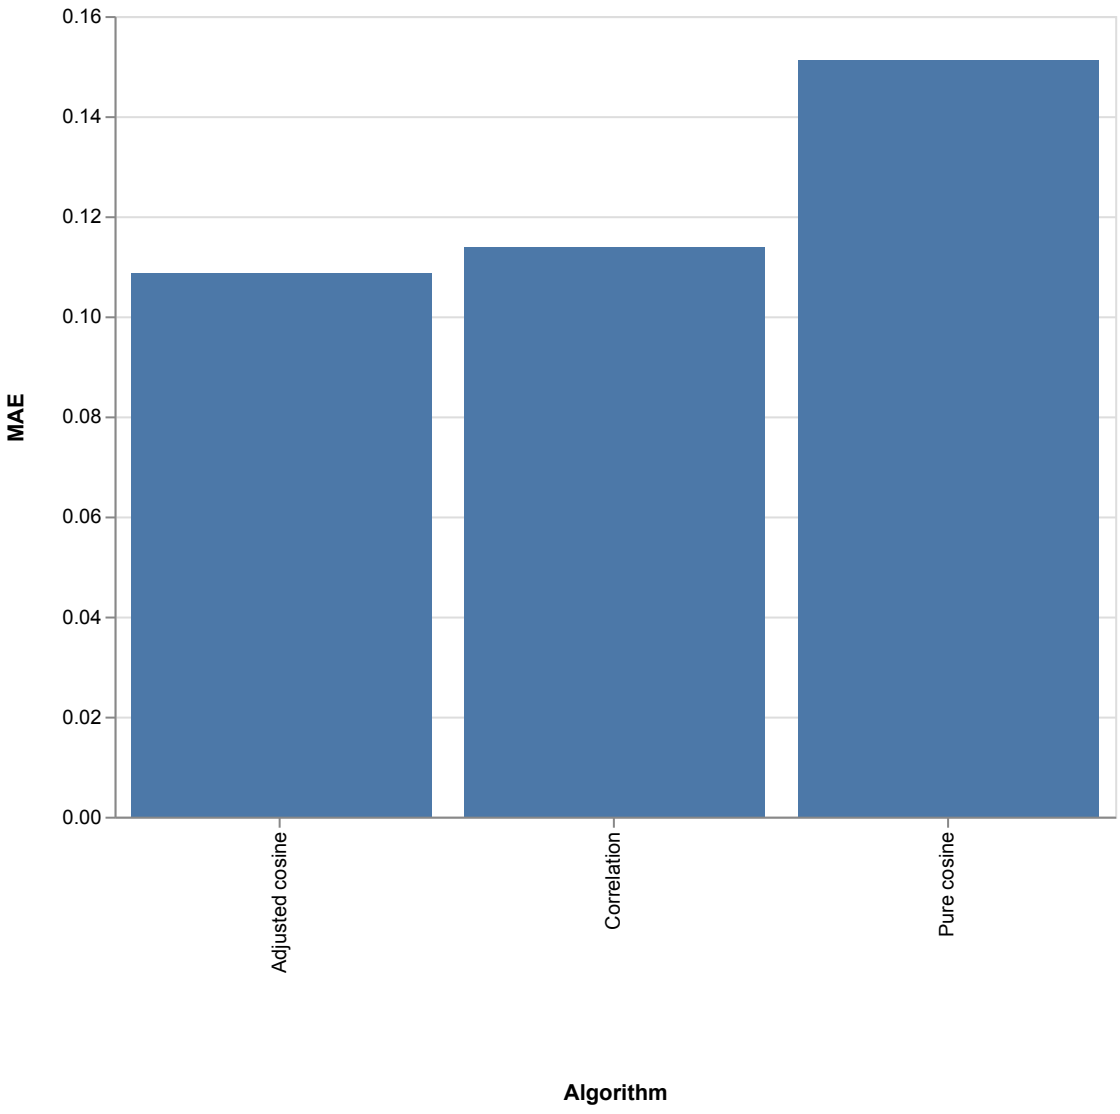

与论文中的结果

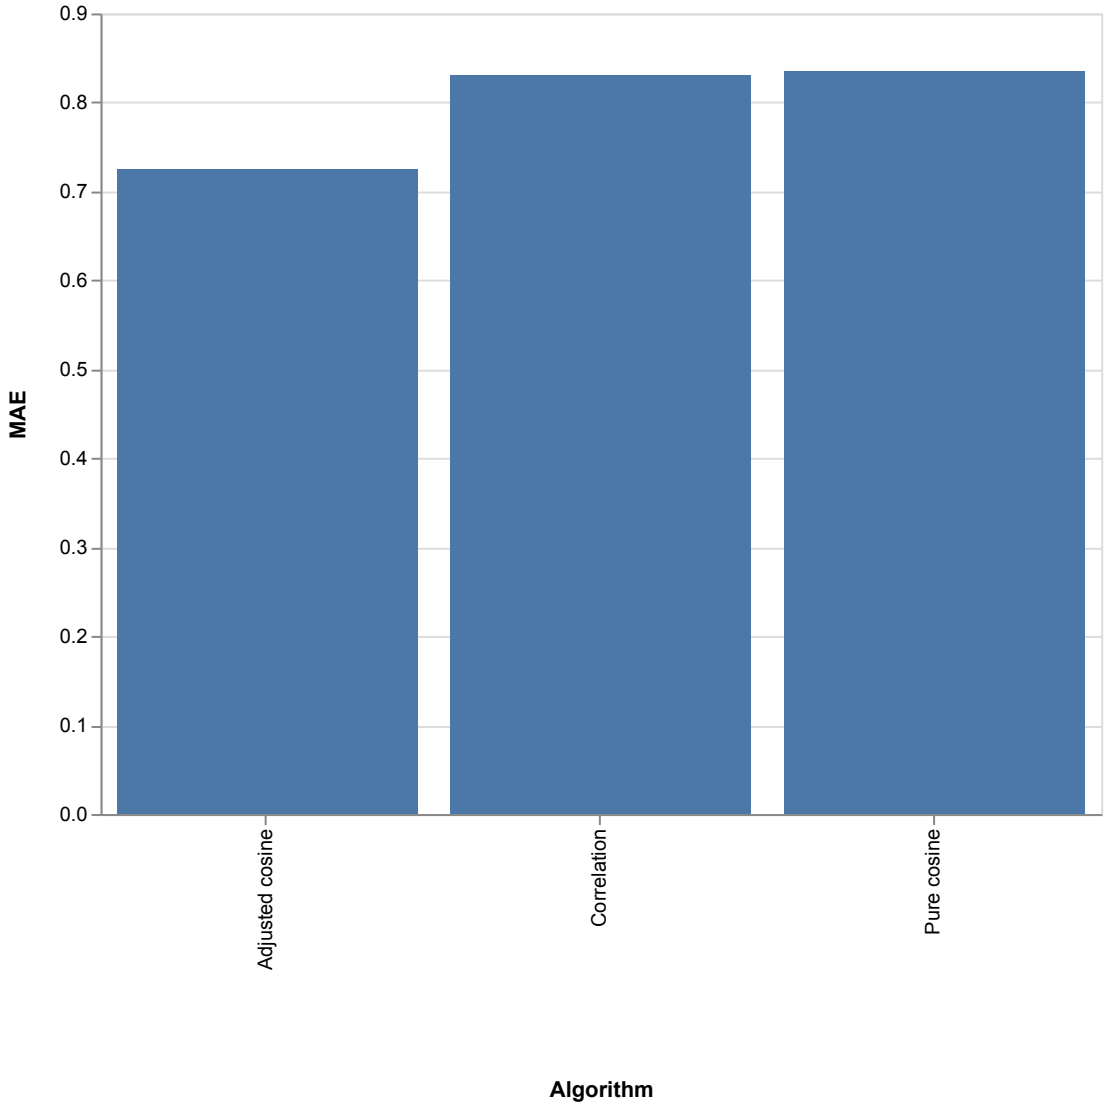

趋势一致。可以认为论文中的结果正确并且可以复现，而且可能是由于数据集或者没有进行用户过滤的原因，我们的MAE比论文中的要好很多。

引用

1. Badrul Sarwar, George Karypis, Joseph Konstan,John Riedl. *Item-Based Collaborative Filtering Recommendation Algorithms*